

基于已验证候选回路的预算约束下 大语言模型辅助高层次综合

Anonymous Submission

Abstract—高层次综合 (HLS) 智能体必须在有限的模型和工具预算内修复并优化陌生内核。已验证候选回路 (VCL) 将验证证据作为候选方案提升的决策依据。其质量评价 (QoR) 分数将有效延迟、容量归一化资源占用和源码变更证据聚合为单一有界效用。QoR 引导的检索增强生成 (QoR-RAG) 复用兼容证据，失败反思 (Failure Reflection) 将工具诊断信息转化为下一轮约束，无需额外模型调用。我们在涵盖六种 HLS 能力的 150 个均衡任务套件上评估了三个开放权重的大语言模型端点。我们报告公开门控完成率，以及提交侧综合产生的 starter 锚定 QoR 代理指标。Qwen3.6-27B 取得最高完成率 (98.7%，148/150 个任务)。DeepSeek V4 Pro 在 25 个优化任务上的代理均值最高 (85.5)，并消耗 5.87M 令牌。Qwen3.5-122B-A10B 使用的令牌最少。每个端点仅有一次运行，因此这些结果不能单独归因于模型架构。

Index Terms—高层次综合，大语言模型智能体，FPGA，检索增强生成，质量评价

I. 用门限证据替代提示词

LLM 智能体可以编辑不熟悉的 HLS 内核，但只有工具报告能够证明正确性和硬件质量。有计量能力的智能体需要一套提升规则：当任何必需验证门失败时，保留已验证的备选方案 [1]。

现有 HLS 智能体实现了代码变换、指令搜索和反馈驱动修复的自动化 [2]–[4]。工具使用型语言智能体交替进行推理和行动 [5]。我们的设计将候选方案的提升决策交由确定性的 HLS 证据控制，并在明确的模型和工具预算约束下运行。

已验证候选回路 (VCL) 贡献了三项发现。(1) **验证契约**。fail-closed 工作流在七个门限前保留已验证备选方案：接口 (Interface)、CSIM、SYNTH、频率 (Frequency)、容量 (Capacity)、所需 CoSIM 和指标完备性 (Metric completeness)。(2) **硬件目标**。有界分数 Q_{HW} 综合有效延迟、容量归一化资源占用和源码变更证据，拒绝代价过高的加速方案。(3) **端点评估**。Qwen3.6-27B 取得最高的公开门限完成率 (98.7%)，DeepSeek 在以 starter 为锚点的优化代理指标上领先，而 Qwen3.5 使用的 token 最少 (第 IV 节)。

II. 工具证据控制智能体 workflow

任务接口暴露可编辑的内核、公开测试、目标器件和预算，同时隐藏秘密测试和冻结参考。控制器在单个运行状态中记录每个候选方案、门限、度量指标、令牌和积分。

VCL 依次运行七个门限：接口 (Interface)、CSIM、SYNTH、频率 (Frequency)、容量 (Capacity)、所需 CoSIM 和指标完备性 (Metric completeness)。频率门强制 100 MHz，容量门强制 U55C 限制，CoSIM 仅在任务需要时适用。定义有效性 $V(c) = \prod_i G_i$ ，其中 $G_i \in \{0, 1\}$ 为各适用门的判定结果；不适用的门贡献为 1。令 b 为已验证备选方案。提升规则为 $P(c) = V(c) \wedge [Q_{HW}(c) > Q_{HW}(b)]$ 。

门失败分为三类，每类通过失败反思驱动特定修复策略，无需额外 LLM 调用。**接口不匹配** (112/691 候选，16%)

触发 API 使用约束以修复函数签名和编译指令语法。**综合瓶颈**——时序违例、资源超额、II 膨胀——产生指令约束 (流水线/展开、数组分区)，来源于 QoR-RAG。**协同仿真死锁** (C/RTL 接口不匹配) 通过插入握手逻辑和端口宽度修正修复。重复候选方案和重复失败触发停止。

图 1 总结该回路。三次实验：691 候选、112 接口拒绝、487 综合门、67 CoSIM 门。CoSIM 失败的单次修复令牌消耗最高。

III. 统一分数拒绝虚假加速

Q_{HW} 将性能增益和资源代价聚合为单一有界效用。令锚点 a 和候选方案 c 分别具有周期延迟 L 、有效周期 p 和启动间隔 II 。性能比 $r_P = (p_a L_a)/(p_c L_c)$ 捕获加速效果。面积比 r_A 使用容量归一化占用 $F(x) = \sum_r x_r / K_r$ (覆盖 LUT、FF、DSP、BRAM、URAM) 防止资源转移导致分数跳变。两项证据因子奖励源码修改 (D , $1.01\times$) 和有效性修复 (F , $2\times$)。综合硬件比 $h = 1.01^D 2^F r_P^{0.55} r_A^{0.45}$ 以 55% 权重偏向性能、45% 偏向面积，基于 99 个冻结 PPA 参考校准。

$Q_{HW} = 1 - 1/(1+h)^2$ 将 $h=1$ (无变化) 映射为 0.75， $h \rightarrow \infty$ 映射为 1， $h \rightarrow 0$ 映射为 0。该映射对膨胀加速连续衰减。预算效率 $E = \max(0.80, 1 - 0.10u_{\text{credit}} - 0.10u_{\text{time}})$ 对过多工具调用折价，保底 0.80，其中各 u 为消耗比例截断至 $[0, 1]$ 。最终分数为

$$S = 100 V(c) Q_{HW} E. \quad (1)$$

提升仅在 $V(c)=1$ 后比较 Q_{HW} ；门失败得 $S=0$ ，效率保底确保有效基线至少获得 60 分。

IV. 完成率与代理质量由不同端点领先

实验协议。三个云端端点在同一个智能体修订版和 Track-A 契约 [6] 下处理相同的 150 个均衡任务套件。我们报告公开门控完成率，以及提交侧综合产生的 starter 锚定 QoR 代理指标。该指标仅覆盖 25 个显式优化任务，并使用公式 (1)；它不包含评测侧隐藏验证和 reference 回退。

TABLE I
完成率与代理质量由不同端点领先。QoR 代理指标为 $100 Q_{HW} E$ ，使用 25 个优化任务的提交侧综合结果与 STARTER 进行比较。

端点	完成数	令牌 (M)	积分	QoR 代理均值	代理 >76
DeepSeek V4 Pro	144/150 (96.0%)	5.87	2,617	85.5	22/25 (88%)
Qwen3.5-122B-A10B	140/150 (93.3%)	1.68	2,375	76.3	7/25 (28%)
Qwen3.6-27B	148/150 (98.7%)	1.92	2,515	79.7	15/25 (60%)

结果。表 I 和逐类别分解 (附录 C) 揭示三种模式。

(1) **Qwen3.6 的公开门控完成率最高**。Qwen3.6-27B 取得了 98.7% 的完成率 (148/150 个任务)，包括结构 CoSIM 修复的 25/25。Qwen3.5 的结构修复完成数为 20/25，是本次比较中的最低分类结果。




Fig. 1. 已验证候选回路。候选方案仅在通过所有适用门且 Q_{HW} 提升后方可替代已验证备选。

(2) **DeepSeek** 以更高令牌成本取得最高优化代理指标。DeepSeek 的平均 Q_{HW} 为 0.880，代理均值为 85.5，其中 22/25 (88%) 的任务高于 76。Qwen3.6 的对应结果为 0.812 和 79.7；Qwen3.5 为 0.775 和 76.3。DeepSeek 使用的令牌是 Qwen3.6 的 3.1×，Qwen3.5 使用的令牌最少。

(3) 三个端点呈现完成率、代理质量和成本之间的权衡。Qwen3.6 的完成率最高，DeepSeek 的优化代理指标最高，Qwen3.5 的令牌用量最低。每个端点只有一次运行，而且托管服务商不同，因此不能把差异单独归因于模型架构。

Takeaway. Qwen3.6 的公开门控完成率最高，DeepSeek 的 starter 锚定优化代理指标最高，Qwen3.5 使用的令牌最少。

V. 局限与后续工作

VCL 将验证证据和 Q_{HW} 作为提升的决策依据，以容量归一化资源占用的连续聚合比替代最差单项增长。Qwen3.6-27B 以 98.7% 取得最高公开门控完成率。DeepSeek V4 Pro 以 85.5 取得最高 starter 锚定优化代理指标，Qwen3.5 使用的令牌最少。这些结果分别刻画完成率、代理质量和模型成本。

该代理指标不包含评测侧隐藏验证和 reference 回退。智能体还依赖于成熟的测试平台输入、固定工具链 (Vitis 2025.2) 和单一 FPGA 平台 (Alveo U55C)。需要匹配消融实验来隔离因果机制：完整智能体、无 QoR-RAG、无测量失败检索和无失败反思——每种变体报告成功数、平均 Q_{HW} 、令牌数、调用次数、积分和挂钟时间。更广泛的语料库和跨平台迁移留待未来工作。

REFERENCES

- [1] Advanced Micro Devices, Inc., *Vitis High-Level Synthesis User Guide*, AMD, 2026, version 2025.2. [Online]. Available: <https://docs.amd.com/r/2025.2-English/ug1399-vitis-hls>
- [2] C. Xiong, C. Liu, H. Li, and X. Li, "HLS Pilot: LLM-based high-level synthesis," in *Proceedings of the 43rd IEEE/ACM International Conference on Computer-Aided Design*, 2024, pp. 1–9.
- [3] H. Xu, H. Hu, and S. Huang, "Optimizing high-level synthesis designs with retrieval-augmented large language models," in *2024 IEEE LLM Aided Design Workshop*, 2024, pp. 1–5.
- [4] R. Li, J. Xiong, X. He, J. Zhao, J. Lv, H. Fang, L. Qi, and X. Wang, "ChatHLS: Towards systematic design automation and optimization for high-level synthesis," *arXiv preprint arXiv:2507.00642*, 2026. [Online]. Available: <https://arxiv.org/abs/2507.00642>

- [5] S. Yao, J. Zhao, D. Yu, N. Du, I. Shafran, K. Narasimhan, and Y. Cao, "ReAct: Synergizing reasoning and acting in language models," in *International Conference on Learning Representations*, 2023.
- [6] FPT 2026 Organizing Committee, "FPT'26 Design Competition: Track A," <https://fpt2026.uark.edu/fpt26-design-competition/>, 2026, accessed July 2026.

APPENDIX A 基准组成

已接受清单冻结了每条上游路径、提交哈希、任务描述、测试和门限配置，保留了 150 个无跨类别内核重叠的任务。表 II 描述了六种均衡能力，每类包含 25 个任务。仅结构类别要求 C/RTL 协同仿真。

TABLE II
任务套件组成。

任务类型	任务数	CoSim
代码生成 (桩 → 内核)	25	0
编译修复	25	0
综合修复	25	0
功能修复 (CSim)	25	0
结构修复 (CoSim)	25	25
QoR 优化	25	0

内核来自两个 AMD 公开仓库的固定提交版本：<https://github.com/Xilinx/Vitis-HLS-Introductory-Examples> (109 个任务, Apache-2.0, aa5c160f) 和 https://github.com/Xilinx/Vitis_Accel_Examples (41 个任务, MIT, 81187602)。150 个变体重用了 65 个独特源路径。

APPENDIX B Track-A 需求映射

所有任务需要 CSim 和 Synth；清单仅要求 25 个结构任务进行 CoSim。表 III 将 Track-A 需求映射到已记录证据。

TABLE III
Track-A 运行契约。

需求	已记录证据
U55C; Vitis 2025.2	容器固定目标器件和工具版本；报告保留执行源码修订哈希。
CSim、Synth、适用 CoSim	必需门缺失或失败则拒绝候选方案。隐藏测试和参考仅评估方可访问。
≥100 MHz；可行	频率门和 U55C 容量门在提升前检查。报告保留延迟、II、周期、LUT、FF、DSP、BRAM、URAM。
令牌/积分核算	每次运行记录令牌和积分。限制：9,000 积分。
三端点对比	DeepSeek V4 Pro、Qwen3.5-122B-A10B、Qwen3.6-27B；同一清单和源码修订。
Docker；可复现	提供 Docker 工作流、公开任务材料、结构化报告和结果生成脚本。
PDF、源码、视频	作者确认 IEEE 格式、两页正文限制、存档内容和五分钟演示。

三个检查点覆盖三种架构体制：DeepSeek V4 Pro (1.6 T MoE, 49 B 激活, FP8)、Qwen3.5-122B-A10B (122 B MoE, 10 B 激活, AWQ-4bit) 和 Qwen3.6-27B (27 B 稠密, FP8)。

APPENDIX C 三端点详细结果

表 IV 和 V 提供第 IV 节背后的逐类别分解。QoR 代理指标为 $100 Q_{HW} E$ (公式 (1))，使用优化任务的提交侧综合结果与 starter 比较。

TABLE IV
各端点逐类别完成率。每类 25 个任务。QoR 代理指标仅覆盖优化任务。

类别	DeepSeek V4	Qwen3.5-122B	Qwen3.6-27B
代码生成	22/25 (88%)	22/25 (88%)	24/25 (96%)
编译修复	25/25 (100%)	25/25 (100%)	25/25 (100%)
综合修复	25/25 (100%)	24/25 (96%)	25/25 (100%)
功能修复	24/25 (96%)	24/25 (96%)	24/25 (96%)
结构修复	23/25 (92%)	20/25 (80%)	25/25 (100%)
QoR 优化	25/25 (100%)	25/25 (100%)	25/25 (100%)
QoR 代理均值 (优化任务)	85.5	76.3	79.7

TABLE V
令牌消耗与积分支出。DeepSeek 消耗了 Qwen3.6 的 3.1× 令牌，并取得最高 QoR 代理指标。

端点	令牌 (百万)	积分
DeepSeek V4 Pro	5.87	2,617
Qwen3.5-122B-A10B	1.68	2,375
Qwen3.6-27B	1.92	2,515

APPENDIX D 复现方法

任务清单: `tasks/track_a_150/candidate_manifest.json`。实验目录: `runs/150_ultimate/technical-paper/results_generated.tex` 中的代理指标宏，是依据第 IV 节的定义从选中的优化任务 `run_report.json` 审计得到的。现有 `update_results.py` 仅面向未来的评估器 `final_report.json` 输入，不生成提交侧代理指标表。

所有实验: 源码快照 `0a06af39777b6ae7f3962afa2910232eaf782e91727e0f184ec168f1a41f106c`, `temperature 0`, 4,096 令牌输出限制, 180 s 请求超时, ≤2 次重试。